




Università Politecnica delle Marche

Sviluppo di un sistema AI multimodale per l'identificazione delle imbarcazioni con immagini satellitari

A.A. 2024/2025

Computer Vision & Deep Learning


Introduzione e Contesto del problema



- Sorveglianza Marittima: Una Sfida Globale
 - Cruciale per commercio, sicurezza (pesca IUU, traffici illeciti) e tutela ambientale.
 - Vastità degli oceani e complessità delle attività rendono il monitoraggio difficile.



- Limiti dei Sistemi di Monitoraggio Attuali
 - AIS (Automatic Identification System): Fornisce dati preziosi, ma spesso incompleto o intenzionalmente disattivato ("dark vessels").
 - Immagini Satellitari (SAR & Ottiche): Offrono copertura ampia ma presentano sfide:
 - Impatto condizioni meteo (per ottiche).
 - Complessità interpretativa e artefatti (per SAR).
 - Grande volume di dati da analizzare.



- Verso Soluzioni Integrate e Intelligenti
 - Necessità di combinare diverse fonti di dati (AIS, SAR, Ottiche) per una visione accurata.
 - Sfruttare la complementarità delle diverse tipologie di immagini satellitari è chiave per superare i limiti individuali.

Stato dell'Arte e Punto di Partenza

- AI per il Rilevamento Imbarcazioni:
 - Il Deep Learning (YOLO, architetture CNN) ha rivoluzionato il settore, superando i metodi tradizionali.
 - Focus su: alta accuratezza, efficienza computazionale e capacità di analizzare immagini satellitari complesse (SAR e Ottiche).
- Studio di Riferimento: Galdelli et al. (2025)
 - Paper: "Multimodal AI-enhanced ship detection for mapping fishing vessels and informing on suspicious activities"
 - Proposta chiave: Pipeline multimodale (Sentinel-1 SAR, Sentinel-2, Ottiche HR + AIS) con modello YOLOv10slight ottimizzato.
 - Contributi: Dataset custom HS3-S2, algoritmo di matchmaking AIS per identificare "dark vessels", analisi di explainability.

Obiettivi del Progetto

- Validazione e Replicazione Metodologica:
 - Replicare i risultati chiave del modello YOLOv10slight (Galdelli et al.) sul dataset HS3-S2.
 - Comprendere e validare la pipeline proposta, stabilendo un benchmark di riferimento.
- Esplorazione di Architetture Avanzate:
 - Estendere l'analisi implementando e valutando l'architettura YOLOv11.
 - Estendere l'analisi implementando e valutando l'architettura YOLOv12.
 - Confrontare le performance delle architetture YOLO più recenti con il baseline YOLOv10slight, addestrando i modelli da zero su input monocanale.
- Miglioramento delle Performance e Ottimizzazione:
 - L'obiettivo finale è sviluppare un sistema di rilevamento imbarcazioni più accurato e/o efficiente.

Fase 1 - Replicazione: Dataset


Dataset	Pixel	Classes	Source	Resolution
SDDCB	256 x 256	39,729	102 Chinese Gaofen-3 108 Sentinel-1	1-15 m
SSDD	500 x 500	2,358	1160 Sentinel-1	1-15 m
HRSID	Varies	16,951	99 Sentinel-1 36 TerraSAR-X 36 1 TanDEM-X	0.5, 1, 3 m
S2_Detection S2_FC	800 x 800 512 x512	1,761 7,911	8 Sentinel-2 15 Sentinel-2	10 m
SDAI	512 x 512	621	Sentinel-2 PlanetScope	3-10 m

Descrizione Dataset:

- Combinati sei fonti open-source (SDDCB, SSDD, HRSID, S2_Detection, S2_FC, SDAI).
- Include immagini SAR (Sentinel-1), multispettrali (Sentinel-2) e ottiche ad alta risoluzione.
- Progettato per robustezza a diversi sensori, risoluzioni e background.

Suddivisione Dataset: 70% training, 15% validazione, 15% test.


Fase 1 - Replicazione: Preprocessing



Data Loading e Preprocessing:

- Formato Dati: Immagini a singolo canale direttamente fornite ai modelli.
- Enfasi su Feature Essenziali: La scala di grigi privilegia forma, dimensione e contrasto imbarcazione/acqua, cruciali per il rilevamento.
- Riduzione del Rumore Visivo: Minimizza l'impatto di variazioni cromatiche potenzialmente fuorvianti.
- Efficienza Computazionale: L'elaborazione di 1 canale riduce il carico computazionale e i requisiti di memoria.
- Segmentazione in Chip: Le immagini monocanale sono state suddivise in patch di dimensioni standard per il training, ovvero 640x640 pixel.


Fase 1 - Replicazione: Architettura e Training



Architettura del Modello YOLOv10slight

- Basato su YOLOv10s, ottimizzato per il rilevamento di piccole imbarcazioni.
- Modifiche chiave rispetto a YOLOv10s standard:
 - Pruning di livelli focalizzati su oggetti grandi.
 - Focus sulla scala P3, più adatta a oggetti piccoli.
 - Mantenimento di blocchi C2fCIB e Concat per l'integrazione di feature multi-scala rilevanti per oggetti piccoli.

Fase 2 - YOLOv11




- Obiettivo:
 - Esplorare i benefici di YOLOv11 (Ultralytics) per il rilevamento avanzato di imbarcazioni.
 - Valutare miglioramenti in accuratezza ed efficienza rispetto al baseline.
- Architettura e Innovazioni Chiave:
 - Estrazione Features Migliorata: YOLOv11 impiega un'architettura Backbone e Neck migliorata per potenziare l'estrazione di features, per un rilevamento più preciso in scene complesse.
 - Efficienza Ottimizzata: Il modello introduce design architeturali e pipeline di training perfezionati per una maggiore velocità di elaborazione, mantenendo un equilibrio ottimale tra prestazioni e risorse.
 - Migliore Precisione con Meno Parametri: Un punto di forza dichiarato è la capacità di raggiungere un'elevata accuratezza (mAP) con un numero inferiore di parametri.

Fase 2 - YOLOv11


- Configurazione per il Nostro Task:
 - Variante: Abbiamo utilizzato diverse configurazioni del modello YOLOv11, in particolare la s e la m, per valutare le performance con diverse risorse computazionali.
 - Training: I modelli YOLOv11s e YOLOv11m sono stati addestrati partendo da pesi inizializzati casualmente direttamente sul dataset HS3-S2.
- La stessa cosa è stata fatta per la YOLOv12, dove abbiamo addestrato partendo da pesi casuali:
 - YOLOv12s
 - YOLOv12m
 - YOLOv12sLight

Fase 2 - YOLOv12



- Architettura del modello YOLOv12
 - Incentrata sull'Attenzione: Discostandosi da approcci puramente CNN, per una migliore comprensione contestuale.
 - Backbone Avanzato: con moduli come R-ELAN e C3K2 per estrazione features robusta.
 - Neck Efficiente: con A2C2f - Area Attention + Conv, Upsample, Concat, per aggregazione multi-scala ottimizzata.
- Innovazioni Chiave (Ultralytics YOLOv12):
 - Meccanismo di Attenzione ad Area (Area Attention): Elaborazione efficiente di campi recettivi con costo computazionale ridotto (negli A2C2f).
 - Aggregazione Features Migliorata (R-ELAN): "Residual Efficient Layer Aggregation Networks" per ottimizzare il flusso di informazioni e l'apprendimento.
 - Ottimizzazioni per Efficienza: Include tecniche come FlashAttention e design mirati a ridurre l'overhead e migliorare il bilanciamento calcolo/precisione.
 - Flessibilità di Input: Supporto per diverse risoluzioni.

Fase 3 - YOLOv12sLight



- Motivazione per la Variante Light:
 - Esplorare un compromesso tra accuratezza e efficienza computazionale.
 - Obiettivo: Ridurre i parametri e il carico computazionale, mantenendo al contempo performance di rilevamento elevate, specialmente per oggetti di piccola scala tipici del nostro dataset.
- Modifica Architetture Chiave: Pruning della Head
 - Sono stati rimossi dei blocchi finali della Head, responsabili della fusione di features per il rilevamento su scale più grandi (P4 e P5), permettendo di creare un modello più snello e veloce per il nostro caso d'uso.
 - I rilevamenti nel nostro dataset si concentrano prevalentemente su scale di feature più piccole (P3).

Scelta degli Iperparametri

Iperparametri	Epochs	Batch Size	Optimizer	Learning Rate	Final LR	Momentum	Weight Decay	Warmup Epochs
Yolov10sLight Yolov11 Yolov12sLight	200	64	SGD	0,01	0,0001	0,9	0,0005	3
Yolov12 Yolov12sLight	200	64	AdamW	0,0001	0,00001	0,9	0,0005	5

Sono state definite due principali configurazioni di iperparametri:

- YOLOv10/v11: È stato utilizzato l'ottimizzatore SGD con momentum, un approccio robusto e consolidato per queste architetture.
- YOLOv12: È stato scelto AdamW, un ottimizzatore adattivo consigliato per architetture più recenti e complesse.
 - Questo ha richiesto un learning rate (lr0) iniziale significativamente più basso (0.0001) per garantire una convergenza stabile ed evitare l'instabilità del training (loss NaN) osservata con valori più alti.


Confronto delle performance

Model	AP50	AP50-95	Precision	Recall	GFLOPs	CO2 (kg)
YOLOv10sLight	0.831	0.528	0.871	0.731	17.2	1.857
YOLOv11s	0.846	0.537	0.888	0.752	26.3	1.636
YOLOv11m	0.851	0.548	0.887	0.759	57.0	2.433
YOLOv12s	0.608	0.308	0.810	0.511	21.2	2.817
YOLOv12m	0.581	0.298	0.773	0.491	67.1	5.124
YOLOv12sLight (AdamW)	0.585	0.288	0.809	0.498	17.0	2.646
YOLOv12sLight (SGD)	0.599	0.320	0.805	0.506	17.0	2.567

Considerazioni:

- YOLOv11m è stato il modello più performante in termini di accuratezza, raggiungendo il miglior valore di AP50 e AP50-95. Anche YOLOv11s e il baseline YOLOv10slight mostrano performance molto buone e competitive.
- Contrariamente alle aspettative, tutte le varianti di YOLOv12 hanno mostrato un significativo calo di performance su tutte le metriche di accuratezza rispetto ai modelli precedenti.
- La nostra variante YOLOv12sLight mostra un'interessante ottimizzazione dell'efficienza: raggiunge quasi la stessa accuratezza di YOLOv12s ma con GFLOPs significativamente inferiori. Questo conferma che la nostra modifica architetturale è efficace nel ridurre il carico computazionale.
- La versione con Optimizer SGD risulta migliore di quella con AdamW per le metriche di mAP

Confronto delle performance



- YOLOv11m (Modello Migliore):
 - Mostra un rilevamento robusto con alti punteggi di confidenza.
 - Identifica correttamente la quasi totalità delle imbarcazioni.
- YOLOv12sLight:
 - Evidenzia le difficoltà del modello: numerosi target mancati (falsi negativi).
 - Predizioni corrette associate a punteggi di confidenza notevolmente più bassi.

Conclusioni

Possibili Cause della performance di YOLOv12:

- Le architetture YOLOv12, più complesse e basate sull'attenzione, potrebbero richiedere dataset più vasti o un pre-training per convergere efficacemente.
- L'assenza di un Hyperparameter Tuning, per limiti di tempo e risorse, potrebbe non aver identificato la configurazione ottimale per questi modelli.
- È possibile un'interazione non ottimale tra l'architettura attention-based di YOLOv12 e l'input a singolo canale.

Sviluppi Futuri:

- Ottimizzazione di YOLOv12:
 - Eseguire un hyperparameter tuning approfondito per le varianti di YOLOv12.
 - Valutare l'impatto del fine-tuning da pesi pre-addestrati per vedere se può aiutare la convergenza iniziale.
- Esplorazione dei Dati di Input:
 - Testare le performance di tutti i modelli utilizzando l'input a 3 canali (immagini a colori) per valutare se il colore apporta informazioni utili e se questo cambia il comportamento di YOLOv12.

Autori:

**Gianluca Baldelli
Federico Beni**

Codici



Dataset



Introduzione e Stato dell'Arte

Architetture e Metodi

Risultati e Conclusioni